특허 명세서

[출원인/발명자 정보]

- **발명자**: 김정욱 (Jeong-Uk Kim)
- **소속**: 상명대학교 전기공학과 (Department of Electrical Engineering, Sangmyung University)
- **주소**: 서울특별시 종로구 홍지문 2 길 7, 03016 (7 Hongimun 2-gil, Jongno-gu, Seoul, 03016)
- **연락처**: jukim@smu.ac.kr

- **과제**: 산업통상자원부/한국에너지기술평가원(KETEP) 지원 연구

[발명의 명칭]

파라메트릭 시뮬레이션 데이터를 이용한 건물 에너지 소비 예측 방법 및 시스템

[기술분야]

본 발명은 건물 에너지 소비 예측 기술에 관한 것으로, 보다 상세하게는 소규모의 파라메트릭 시뮬레이션 데이터를 이용하여 임의의 건물에 대한 에너지 소비를 위치 정보 없이 예측하는 방법 및 시스템에 관한 것이다.

[배경기술]

건물 부문은 전 세계 에너지 소비의 약 40%를 차지하며, 건물 에너지 소비를 정확하게 예측하는 것은 전력 계통 운영, 수요 반응, 에너지 효율 개선에 필수적이다. 특히 과거 데이터가 없는 신규 건물이나 계측되지 않은 건물에 대해 에너지 소비를 예측하는 제로샷(zero-shot) 예측 기술의 수요가 증가하고 있다.

종래 기술에 따르면, 미국 NREL(National Renewable Energy Laboratory)의 BuildingsBench 는 약 90 만 동의 합성 건물 데이터(Buildings-900K)를 이용하여 트랜스포머(Transformer) 기반 시계열 예측 모델을 학습하는 방법을 제시하였다(P. Emami et al., “BuildingsBench: A Large-Scale Dataset of 900K Buildings and Benchmark for Short-Term Load Forecasting”, NeurIPS 2023). 이 방법은 대규모 합성 건물 데이터셋을 구축하는 데 상당한 시뮬레이션 비용 및 저장 공간이 소요되며, 건물 스톡 모델(stock model)의 고정된 분포에 의존하여 학습 데이터의 운영 패턴 다양성이 제한되는 문제가 있다.

또한, 머신러닝 기반 건물 에너지 예측 분야에서는 LSTM, GRU 등 순환 신경망 구조(S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory”, Neural Computation, 1997)와 어텐션 메커니즘을 활용한 다양한 시계열 예측 모델이 연구되어 왔으나, 이들은 대부분 특정 건물의 과거 실측 데이터를 학습에 필요로 하여 미계측 건물에 적용하기 어렵다는 한계가 있다.

한편, 시계열 예측 분야에서는 학습 데이터와 테스트 데이터 간의 분포 차이(distribution shift)를 보완하기 위해 역변환 가능한 인스턴스 정규화(Reversible Instance Normalization, RevIN) 기법이 연구된 바 있다(T. Kim et al., “Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift”, ICLR 2022). 이 기법은 각 입력 시퀀스의 통계량으로 정규화 후 예측하고 역정규화하여 출력하는 방식으로, 단일 건물 또는 관련 도메인의 시계열 예측에 적용되어 왔다. 그러나 소규모의 파라메트릭 시뮬레이션 데이터를 학습 데이터로 사용하는 건물 에너지 제로샷 예측 문제에 이를 적용하여 대규모 데이터 기반 모델과 동등한 성능을 달성한 사례는 없었다.

아울러 종래 기술은 예측 대상 건물의 위도, 경도 등 지리적 정보를 모델 입력으로 요구하여, 위치 정보가 부재한 환경에서의 배포에 제약이 있다.

종래 기술에서는 제로샷 에너지 예측 성능이 학습 데이터의 규모에 비례한다는 것이 지배적 가정이었다. 소규모 데이터의 운영 패턴 다양성을 체계적으로 설계함으로써 대규모 데이터를 대체하는 접근은 당업자에게 자명하지 않았으며, 실제로 BuildingsBench 에서도 0.067 에포크만으로 과적합이 발생하였으나 이를 다양성 문제로 재해석하는 시도는 없었다.

따라서 소규모의 시뮬레이션 데이터만으로도 대규모 데이터 기반 모델과 동등한 성능을 달성하면서, 위치 정보 없이도 범용적으로 적용 가능한 건물 에너지 예측 기술이 요구된다.

[발명이 해결하고자 하는 과제]

본 발명이 해결하고자 하는 과제는, 대규모 건물 데이터셋을 구축하지 않고도 높은 에너지 예측 정확도를 달성할 수 있는 건물 에너지 소비 예측 방법을 제공하는 것이다.

본 발명이 해결하고자 하는 다른 과제는, 예측 대상 건물의 위치 정보 없이도 범용적으로 적용 가능한 건물 에너지 소비 예측 시스템을 제공하는 것이다.

본 발명이 해결하고자 하는 또 다른 과제는, 건물 운영 스케줄의 다양성을 체계적으로 확보하여 미지 건물에 대한 일반화 성능을 향상시키는 파라메트릭 시뮬레이션 데이터 생성 방법을 제공하는 것이다.

[과제의 해결 수단]

상기 과제를 해결하기 위하여, 본 발명의 일 실시예에 따른 건물 에너지 소비 예측 방법은 다음의 단계를 포함한다.

(a) 복수의 건물 아키타입 각각에 대하여, 건물 운영 스케줄을 결정하는 복수의 파라미터를 다차원 라틴 하이퍼큐브 샘플링(Latin Hypercube Sampling)에 의해 생성하는 파라미터 생성 단계;

(b) 상기 생성된 파라미터에 기초하여 에너지 시뮬레이션 프로그램을 실행하고, 건물별 시간당 에너지 소비 데이터를 포함하는 학습 데이터셋을 생성하는 시뮬레이션 단계;

(c) 상기 학습 데이터셋의 시간당 에너지 소비 데이터에 역변환 가능한 인스턴스 정규화(Reversible Instance Normalization)를 적용하여, 각 건물의 문맥 구간(context window)의 평균 및 표준편차로 정규화한 후, 인코더-디코더 기반 시계열 예측 모델을 학습하는 학습 단계; 및

(d) 예측 대상 건물의 소정 기간의 에너지 소비 이력 데이터를 입력으로 하여, 상기 학습된 모델에 의해 미래의 에너지 소비를 예측하되, 상기 예측 대상 건물의 위치 정보를 입력하지 않고 예측을 수행하는 예측 단계;

를 포함하는 것을 특징으로 한다.

[발명의 효과]

본 발명에 따르면 다음과 같은 효과가 있다.

첫째, 700 동 수준의 소규모 파라메트릭 시뮬레이션 데이터만으로 90 만 동의 대규모 데이터 기반 모델과 동등하거나 우수한 예측 성능을 달성할 수 있다. 실험 결과, 955 동의 상업용 건물에 대한 제로샷 평가에서 5-시드 평균 중앙값 CVRMSE 13.11 ± 0.17%(최고 시드 12.93%)를 달성하여, 종래 기술의 13.27% 대비 동등 수준(최고 시드는 0.34%p 개선)을 확인하였다.

둘째, 건물의 위도, 경도 등 위치 정보 없이도 기후대가 다른 건물에 대해 범용적으로 적용 가능하다. 인스턴스 정규화가 건물 간 분포 차이를 흡수하므로 지리 메타데이터가 불필요하다.

셋째, 12 차원 라틴 하이퍼큐브 샘플링에 의한 파라메트릭 스케줄 설계가 건물 운영 패턴의 공간을 효율적으로 커버하여, 아키타입당 5 개 샘플(총 70 동) 수준에서 이미 종래 기술의 성능에 도달하고 아키타입당 10 개 샘플(총 140 동) 이상이면 성능이 포화되는 것을 확인하였다.

넷째, 시뮬레이션 데이터로 학습한 모델이 실측 건물(한국 편의점 218 동)에 대해서도 중앙값 CVRMSE 12.30%를 달성하여, 시뮬레이션-실측 간 전이(sim-to-real transfer)가 유효함을 확인하였다.

[발명을 실시하기 위한 구체적인 내용]

1. 시스템 구성 (도 1 참조)

본 발명의 건물 에너지 소비 예측 시스템(100)은 다음의 구성요소를 포함한다.

- 파라미터 생성부(110): 건물 아키타입별로 12 차원 운영 파라미터를 LHS 로 샘플링
- 시뮬레이션 수행부(120): 에너지 시뮬레이션 프로그램(EnergyPlus)을 실행하여 연간 시간별 에너지 데이터 생성

- 데이터 전처리부(130): Box-Cox 변환 및 시계열 윈도우 생성
- 모델 학습부(140): 인스턴스 정규화 + 트랜스포머 모델 학습
- 에너지 예측부(150): 학습된 모델로 대상 건물의 에너지 소비 예측

2. 파라미터 생성 단계 (도 2 참조)

상기 파라미터 생성 단계(a)에서, 건물 운영 스케줄을 결정하는 12 개의 파라미터는 다음과 같다.

번호	파라미터명	범위	설명
1	op_start	0~12 시간	건물 운영 시작 시각
2	op_duration	8~24 시간	일일 운영 지속 시간
3	baseload_pct	25~98%	비운영 시간대의 기저부하 비율
4	weekend_factor	0~1.2	주말/주중 부하 비율
5	ramp_hours	0.5~4 시간	운영 전환 경사 시간
6	equip_always_on	30~95%	상시 가동 장비 비율
7	daily_noise_std	5~35%	일별 부하 변동 노이즈
8	scale_mult	0.3~3.0	부하 밀도 배율
9	night_equipment_frac	30~95%	야간 장비 잔류 비율
10	weekly_break_prob	0~25%	주별 패턴 이탈 확률
11	seasonal_amplitude	0~30%	계절별 부하 진폭
12	process_load_frac	0~50%	상시 공정 부하 비율

상기 12 개 파라미터는 라틴 하이퍼큐브 샘플링(Latin Hypercube Sampling, LHS)에 의해 생성된다. LHS 는 각 파라미터의 범위를 N 등분하고, 각 차원에서 정확히 하나의 샘플이 각 구간에 위치하도록 배치하는 공간 충전(space-filling) 설계 방법으로, 동일한 샘플 수로 무작위 샘플링 대비 파라미터 공간을 효율적으로 커버한다. 본 발명에서 상기 N 은 아키타입당 생성하는 파라미터 세트의 수(예: 50)와 동일하게 설정된다.

본 발명의 일 실시예에서, 14 개의 건물 아키타입(사무실, 소매점, 학교, 호텔, 병원, 중층 아파트, 고층 아파트, 소형 사무실, 대형 사무실, 창고, 스트립몰, 풀서비스 레스토랑, 퀵서비스 레스토랑, 대학교) 각각에 대해 50 개의 LHS 샘플을 생성하여, 총 700 동의 건물 파라미터 세트를 구성한다.

3. 시뮬레이션 단계

상기 시뮬레이션 단계(b)에서, 각 파라미터 세트에 기초하여 건물 에너지 시뮬레이션 프로그램의 입력 파일을 수정한다. 본 발명의 일 실시예에서는 EnergyPlus 시뮬레이션 프로그램의 IDF(Input Data File)를 수정하며, 상기 IDF 수정은 다음을 포함한다.

- 외피(envelope) 사양: 지역 건축 기준에 따른 단열 성능

- HVAC 시스템: 아키타입별 냉난방 시스템 유형
- 내부 부하(internal loads): 조명, 장비, 재실 밀도
- 운영 스케줄: 상기 12 개 파라미터에 의해 결정되는 시간별 부하 패턴

시뮬레이션은 TMY(Typical Meteorological Year) 기상 데이터를 이용하여 연간(8,760 시간) 수행되며, 시간별 전기 소비량(kWh)이 추출된다. 상기 기상 데이터는 한국 기상청의 서울, 부산, 대구, 강릉, 제주 5 개 지역의 TMY 기상 파일을 포함할 수 있으며, 각 IDF 파일에 대해 해당 지역의 기상 데이터가 적용된다.

4. 학습 단계 (도 3 참조)

상기 학습 단계(c)에서, 역변환 가능한 인스턴스 정규화(RevIN)와 인코더-디코더 트랜스포머 모델이 결합된다.

인스턴스 정규화: 입력 시계열 $x = \{x_1, x_2, \ldots, x_T\}$에 대하여, 문맥 구간(context window, 예: 168 시간)의 평균 μ_{ctx} 와 표준편차 σ_{ctx} 를 산출하고, 정규화된 입력 $x_{norm} = (x - \mu_{ctx}) / \sigma_{ctx}$ 를 모델에 입력한다. 모델의 출력 $\hat{y}_{norm}$ 에 대하여 역정규화 $\hat{y} = \hat{y}_{norm} \times \sigma_{ctx} + \mu_{ctx}$ 를 적용하여 원래 스케일의 예측값을 복원한다.

이 정규화에 의해, 건물 간 부하 크기 및 변동성의 차이가 제거되어 모델이 시간적 패턴(temporal pattern)에 집중할 수 있으며, 위치 정보 없이도 다양한 건물에 대한 범용 예측이 가능해진다.

트랜스포머 모델: 인코더-디코더 구조(3 개 인코더 레이어, 3 개 디코더 레이어, 모델 차원 512)로 구성되며, 168 시간의 문맥 입력으로부터 24 시간의 가우시안 분포 파라미터(평균 μ, 표준편차 σ)를 자기회귀적으로 생성한다. 손실 함수는 가우시안 음의 로그 우도(Gaussian NLL)를 사용한다.

학습 조건: AdamW 옵티마이저(학습률 6×10^{-5}), 코사인 어닐링 스케줄, 18,000 스텝 학습. 데이터 증강으로 윈도우 시프트(±1~6 시간), 가우시안 노이즈(표준편차 σ=0.02), 진폭 스케일링(균일 분포 U[0.85, 1.15])을 적용한다. 상기 학습 스텝 수(18,000 스텝)는 전체 학습 데이터에 대한 에포크 수를 기준으로 결정되며, 데이터의 크기 또는 모델의 용량에 따라 조정될 수 있다.

5. 예측 단계

상기 예측 단계(d)에서, 예측 대상 건물의 과거 168 시간(1 주일)의 에너지 소비 이력 데이터가 입력된다. 상기 이력 데이터에 인스턴스 정규화가 적용된 후 학습된 트랜스포머 모델에 의해 미래 24 시간의 에너지 소비가 예측된다. 예측 시 건물의 위도, 경도, 건물 유형 등의 메타데이터는 입력되지 않으며, 본 발명의 일 실시예에서 위도 및 경도 입력값은 0 으로 설정하거나 위치 임베딩 레이어를 사용하지 않는 방식으로 구현된다. 이에 따라 에너지 이력 데이터와 시간 특징(시각, 요일, 일자)만으로 예측이 수행된다.

6. 실시예

본 발명의 방법을 적용한 실험 결과를 이하에 기술한다.

실험 조건: - 학습 데이터: 14 개 건물 아키타입 × 50 LHS 샘플 = 700 동 (서울·부산·대구·강릉·제주 5 개 도시의 TMY 기상 데이터로 각 IDF 시뮬레이션 수행) - 평가 데이터: BuildingsBench 955 동 상업용 건물 (BDG-2 611 동, Electricity 344 동) - 평가 지표: 건물별 CVRMSE 의 중앙값 - 종래 기술 비교: BuildingsBench Transformer-M (900,000 동 학습)

결과:

방법	학습 건물 수	위치 정보	CVRMSE (%)
종래 기술 (BuildingsBench)	900,000	사용	13.27
본 발명 (RevIN 적용, 5-시드 평균)	700	미사용	13.11 ± 0.17
본 발명 (RevIN 적용, 최고 시드)	700	미사용	12.93
본 발명 (RevIN 미적용, 3-시드 평균)	700	미사용	14.72 ± 0.28
종래 데이터 700 동 + RevIN	700	미사용	15.28
종래 데이터 700 동 + RevIN + 데이터증강	700	미사용	14.26

본 발명에 의한 700 동 학습 모델(RevIN 적용, 5-시드 평균)은 종래 기술의 900,000 동 학습 모델과 동등한 CVRMSE 13.11 ± 0.17%를 달성하였으며, 최고 시드는 12.93%로 종래 기술 대비 0.34%p 개선되었다. 동일한 700 동이라도 본 발명의 파라메트릭 시뮬레이션 데이터는 종래 데이터에 데이터증강을 적용한 가장 유리한 조건(14.26%) 대비 1.15%p, 데이터증강 미적용 종래 데이터(15.28%) 대비 2.17%p 우수하였다(데이터 설계 효과). 이는 RevIN 효과(1.61%p)보다 데이터 설계의 기여도가 더 큼을 의미한다.

또한 한국 편의점 218 동의 실측 데이터에 대한 제로샷 평가에서 본 발명은 12.30%, 종래 기술은 13.14%의 CVRMSE 를 달성하여, 실측 환경에서도 본 발명의 우수성이 확인되었다.

N-스케일링 분석: 아키타입당 건물 수(n)를 1 부터 80 까지 변화시킨 결과, n=5(총 70 동)에서 이미 종래 기술의 CVRMSE 13.27%에 도달(13.28 ± 0.12%, 5-시드 평균)하고, n=10(총 140 동) 이상에서 성능이 포화하여 추가 건물 수 증가에 의한 개선이 미미한 것으로 확인되었다. n=80(총 1,120 동)에서의 성능은 13.15%로, 본 발명의 방법이 1,120 동 규모에서도 유효하게 동작함이 확인되었다.

n (아키타입당)	총 건물 수	CVRMSE (%)
1	14	14.72
3	42	13.47
5	70	13.28 ± 0.12 (5-시드)
10	140	13.18

n (아키타입당)	총 건물 수	CVRMSE (%)
20	280	13.23
50	700	12.93
70	980	13.20
80	1,120	13.15

상기 표로부터 n=10(총 140 동) 이상에서 성능이 실질적으로 포화됨을 확인할 수 있다. n=10 이후의 성능 포화 경향으로부터, 아키타입당 100 개(총 1,400 동)의 파라미터 세트를 사용하더라도 본 발명의 방법이 동등 이상의 성능으로 작동할 것임이 예상된다. 따라서 아키타입당 5 개 이상 100 개 이하의 파라미터 세트 범위는 본 실시예의 실험 결과 및 성능 포화 경향에 의해 충분히 뒷받침된다.

[청구범위]

[청구항 1]

건물 에너지 소비 예측 방법에 있어서,

(a) 복수의 건물 아키타입 각각에 대하여, 건물 운영 시작 시각, 운영 지속 시간, 기저부하 비율, 주말 부하 비율, 야간 장비 잔류 비율, 일별 변동 노이즈, 및 부하 밀도 배율을 포함하는 복수의 운영 파라미터를 다차원 라틴 하이퍼큐브 샘플링에 의해 생성하는 단계;

(b) 상기 생성된 운영 파라미터에 기초하여 건물 에너지 시뮬레이션을 수행하고, 건물별 시간당 에너지 소비 데이터를 포함하는 학습 데이터셋을 생성하는 단계;

(c) 상기 학습 데이터셋에 역변환 가능한 인스턴스 정규화를 적용하여 시계열 예측 모델을 학습하되, 상기 인스턴스 정규화는 입력 시계열의 소정 구간의 평균 및 표준편차에 의해 정규화하고, 출력에 대하여 상기 평균 및 표준편차로 역정규화하는 것인, 학습 단계; 및

(d) 예측 대상 건물의 에너지 소비 이력 데이터를 상기 학습된 모델에 입력하여 미래의 에너지 소비를 예측하되, 상기 예측 대상 건물의 위치 정보를 입력하지 않고 예측을 수행하는 단계;

를 포함하는 건물 에너지 소비 예측 방법.

[청구항 2]

제 1 항에 있어서, 상기 복수의 운영 파라미터는 12 개의 연속 파라미터를 포함하고, 상기 12 개의 파라미터는 운영 시작 시각(op_start), 운영 지속 시간(op_duration), 기저부하 비율(baseload_pct), 주말 부하 비율(weekend_factor), 전환 경사 시간(ramp_hours), 상시 가동 장비 비율(equip_always_on), 일별 변동 노이즈(daily_noise_std), 부하 밀도 배율(scale_mult), 야간 장비 잔류 비율(night_equipment_frac), 주별 패턴 이탈 확률(weekly_break_prob), 계절별

부하 진폭(seasonal_amplitude), 및 상시 공정 부하 비율(process_load_frac)인 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 3]

제 1 항에 있어서, 상기 복수의 건물 아키타입은 10 종 이상의 건물 유형을 포함하고, 각 아키타입에 대하여 상기 라틴 하이퍼큐브 샘플링에 의해 5 개 이상 100 개 이하의 파라미터 세트를 생성하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 4]

제 1 항에 있어서, 상기 시계열 예측 모델은 인코더-디코더 트랜스포머 구조를 가지며, 168 시간의 문맥 입력으로부터 24 시간의 에너지 소비를 자기회귀적으로 예측하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 5]

제 1 항에 있어서, 상기 학습 데이터셋의 총 건물 수가 2,000 동 이하이고, 상기 학습된 모델이 상기 학습 데이터에 포함되지 않은 건물에 대하여 제로샷(zero-shot) 예측을 수행하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 6]

제 1 항에 있어서, 상기 (b) 단계의 에너지 시뮬레이션은 EnergyPlus 프로그램에 의해 수행되고, 연간 8,760 시간의 시간별 전기 소비량을 생성하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 7]

제 1 항에 있어서, 상기 (c) 단계에서, 상기 학습 데이터에 Box-Cox 변환을 적용한 후 인스턴스 정규화를 수행하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 8]

제 1 항에 있어서, 상기 (c) 단계에서, 데이터 증강(augmentation)이 적용되며, 상기 데이터 증강은 윈도우 시프트, 가우시안 노이즈 추가, 및 진폭 스케일링 중 하나 이상을 포함하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 9]

제 1 항에 있어서, 상기 (d) 단계에서, 상기 예측은 확률적 예측이며, 상기 모델이 미래 시간 단위별 에너지 소비의 평균 및 표준편차를 포함하는 가우시안 분포 파라미터를 출력하는 것을 특징으로 하는 건물 에너지 소비 예측 방법.

[청구항 10]

건물 에너지 소비 예측 시스템에 있어서,

복수의 건물 아키타입에 대하여 건물 운영 파라미터를 다차원 라틴 하이퍼큐브 샘플링에 의해 생성하는 파라미터 생성부;

상기 운영 파라미터에 기초하여 건물 에너지 시뮬레이션을 수행하여 학습 데이터를 생성하는 시뮬레이션 수행부;

상기 학습 데이터로부터 시계열 윈도우를 생성하는 데이터 전처리부;

상기 전처리된 학습 데이터에 역변환 가능한 인스턴스 정규화를 적용하여 시계열 예측 모델을 학습하는 모델 학습부; 및

예측 대상 건물의 에너지 소비 이력 데이터를 입력받아, 위치 정보 없이 미래의 에너지 소비를 예측하는 에너지 예측부;

를 포함하는 건물 에너지 소비 예측 시스템.

[청구항 11]

제 10 항에 있어서, 상기 파라미터 생성부는, 운영 시작 시각(op_start), 운영 지속 시간(op_duration), 기저부하 비율(baseload_pct), 주말 부하 비율(weekend_factor), 전환 경사 시간(ramp_hours), 상시 가동 장비 비율(equip_always_on), 일별 변동 노이즈(daily_noise_std), 부하 밀도 배율(scale_mult), 야간 장비 잔류 비율(night_equipment_frac), 주별 패턴 이탈 확률(weekly_break_prob), 계절별 부하 진폭(seasonal_amplitude), 및 상시 공정 부하 비율(process_load_frac)의 12 개의 연속 파라미터를 생성하는 것을 특징으로 하는 건물 에너지 소비 예측 시스템.

[청구항 12]

제 10 항에 있어서, 상기 모델 학습부의 시계열 예측 모델은 인코더-디코더 트랜스포머를 포함하고, 상기 에너지 예측부는 168 시간의 이력 데이터로부터 24 시간의 에너지 소비를 예측하는 것을 특징으로 하는 건물 에너지 소비 예측 시스템.

[청구항 13]

컴퓨터에 의해 실행 가능한 명령어를 저장하는 컴퓨터 판독 가능 기록매체에 있어서,

상기 명령어는 프로세서에 의해 실행될 때, 복수의 건물 아키타입 각각에 대하여 건물 운영 시작 시각, 운영 지속 시간, 기저부하 비율, 주말 부하 비율, 야간 장비 잔류 비율, 일별 변동 노이즈, 및 부하 밀도 배율을 포함하는 복수의 운영 파라미터를 다차원 라틴 하이퍼큐브 샘플링에 의해 생성하는 동작; 상기 운영 파라미터에 기초하여 건물 에너지 시뮬레이션을 수행하여 건물별

시간당 에너지 소비 데이터를 포함하는 학습 데이터를 생성하는 동작; 상기 학습 데이터에 역변환 가능한 인스턴스 정규화를 적용하되, 입력 시계열의 소정 구간의 평균 및 표준편차로 정규화하고 출력에 대하여 역정규화하는 방식으로 시계열 예측 모델을 학습하는 동작; 및 예측 대상 건물의 에너지 소비 이력 데이터를 입력받아, 상기 예측 대상 건물의 위치 정보를 입력하지 않고 미래의 에너지 소비를 예측하는 동작;

을 수행하게 하는 컴퓨터 판독 가능 기록매체.

[요약서]

[요약]

본 발명은 소규모의 파라메트릭 시뮬레이션 데이터를 이용한 건물 에너지 소비 예측 방법 및 시스템에 관한 것이다. 12 차원 라틴 하이퍼큐브 샘플링으로 건물 운영 파라미터를 생성하고, 에너지 시뮬레이션에 의해 학습 데이터를 구축한 후, 역변환 가능한 인스턴스 정규화와 트랜스포머 모델을 결합하여 학습한다. 학습된 모델은 예측 대상 건물의 위치 정보 없이 에너지 소비 이력만으로 미래 소비를 예측한다. 700 동의 시뮬레이션 데이터로 학습한 모델이 90 만 동의 종래 기술 대비 동등 이상의 예측 성능(CVRMSE 13.11 ± 0.17% (5-시드 평균, 최고 시드 12.93%) vs 13.27%)을 달성한다.

[대표도]

도 1

[도면의 간단한 설명]

도 1 은 본 발명의 건물 에너지 소비 예측 시스템의 전체 구성도이다. 도 2 는 12 차원 라틴 하이퍼큐브 샘플링에 의한 파라미터 생성 과정을 나타내는 흐름도이다. 도 3 은 역변환 가능한 인스턴스 정규화를 포함하는 모델 학습 과정을 나타내는 흐름도이다. 도 4 는 학습 건물 수(N)에 따른 예측 성능(CVRMSE) 변화를 나타내는 그래프이다. 도 5 는 본 발명과 종래 기술의 성능 비교를 나타내는 그래프이다.

[도면]

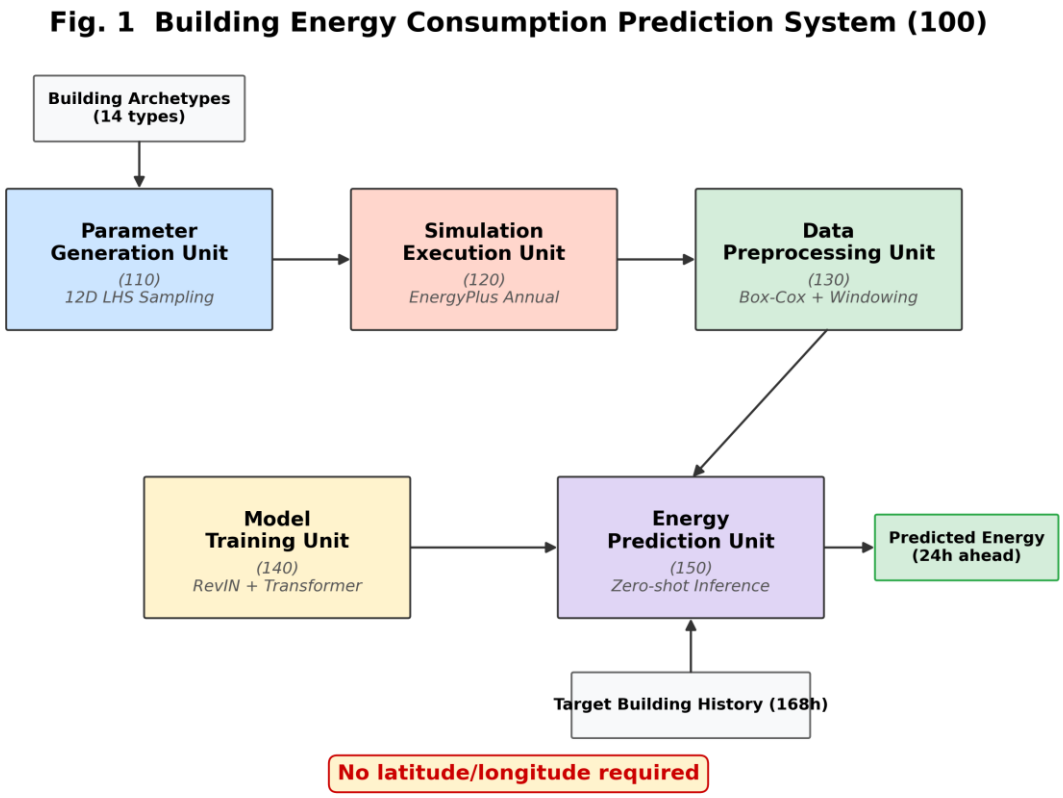

도 1 — 건물 에너지 소비 예측 시스템 전체 구성도

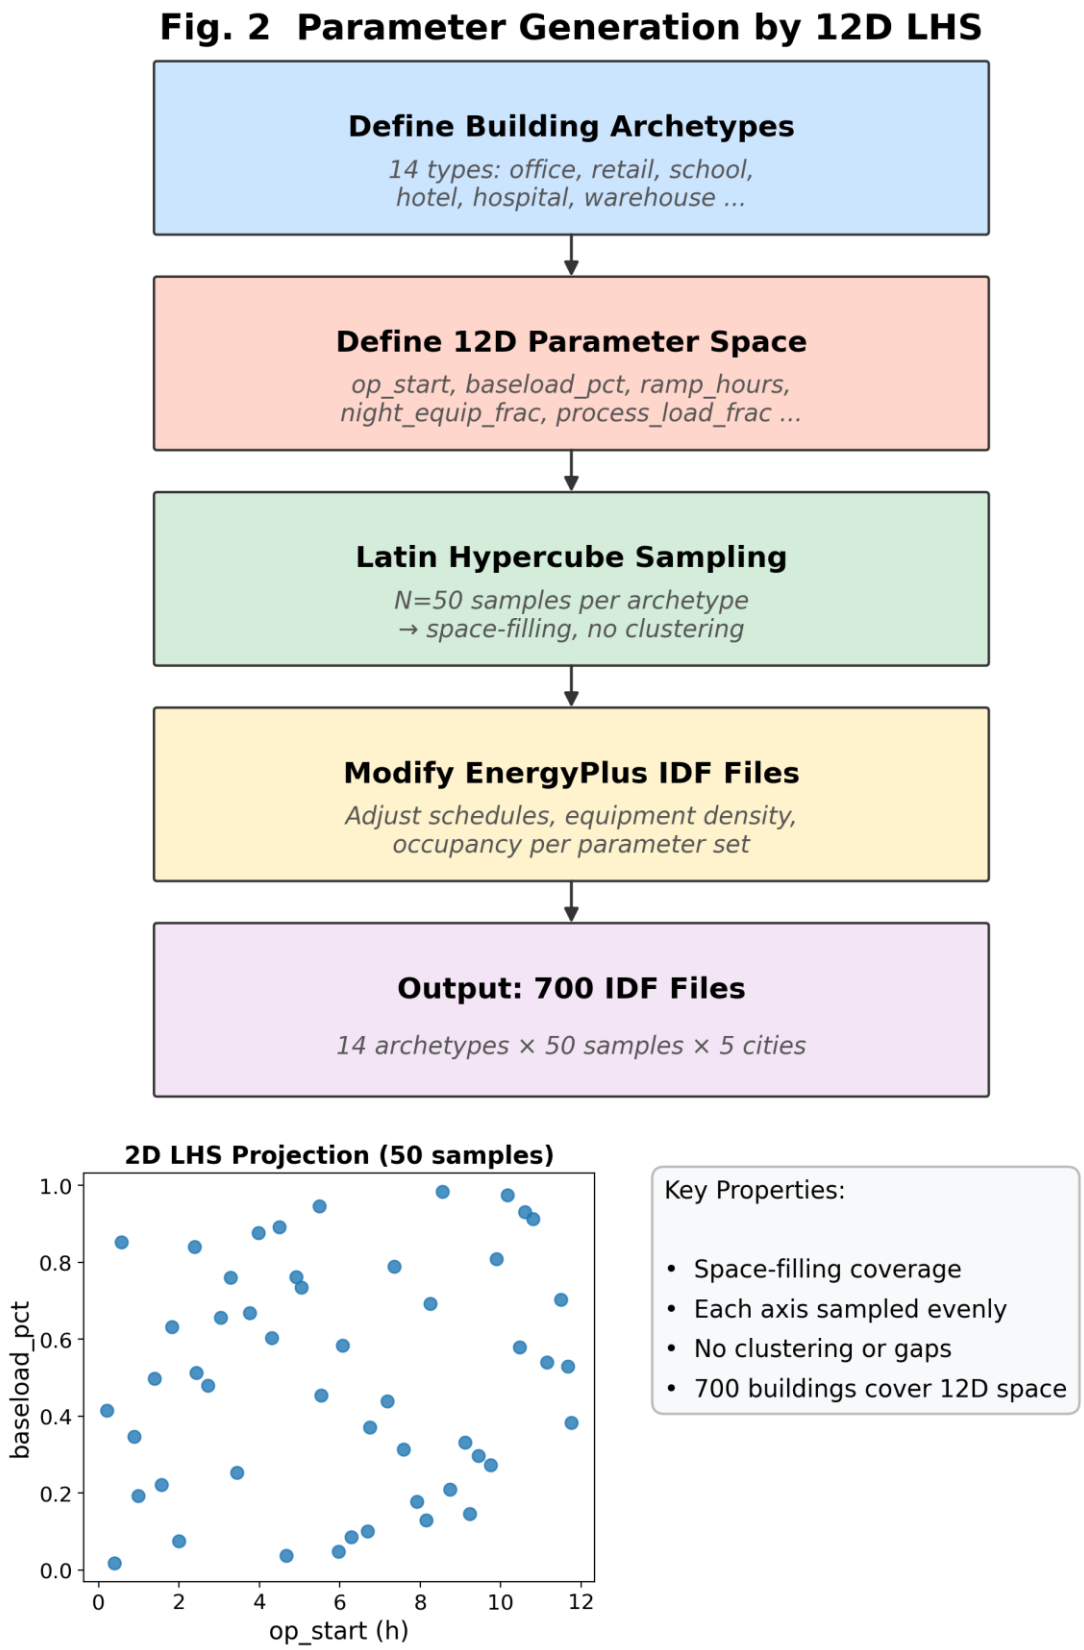

도 2 — 12 차원 LHS 파라미터 생성 흐름도

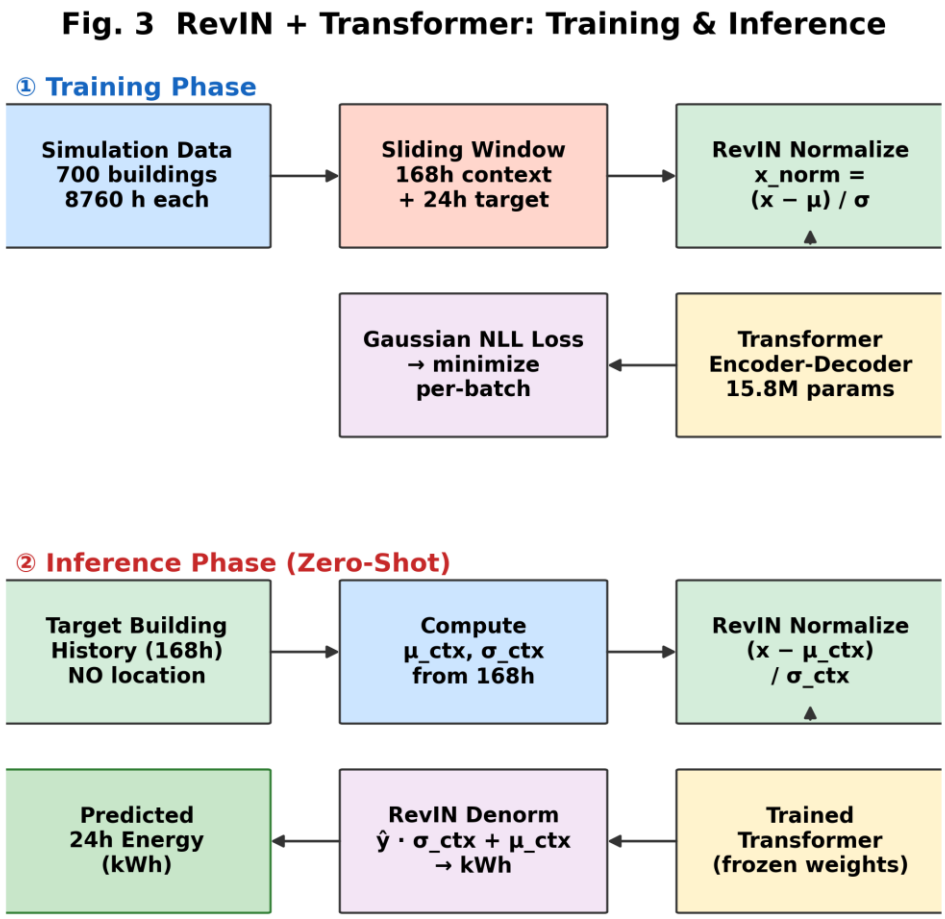

RevIN removes per-building magnitude → model learns temporal shape only → no location metadata needed

도 3 — RevIN + Transformer 모델 학습 흐름도

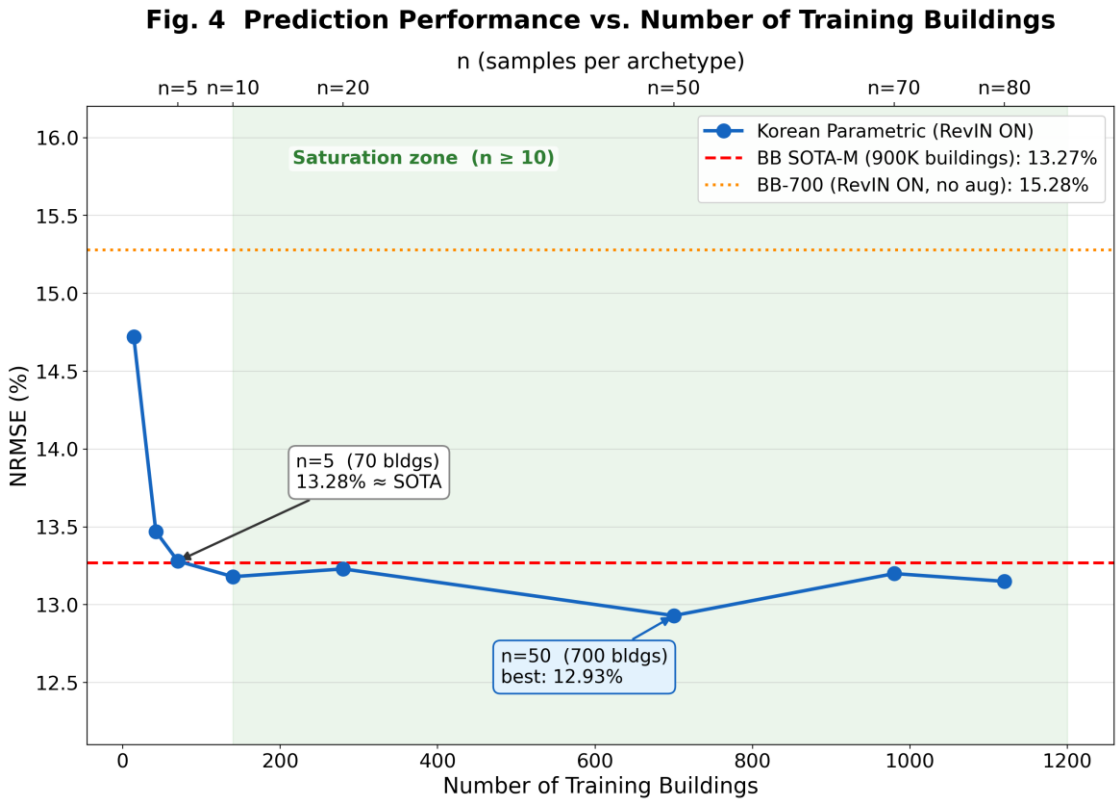

도 4 — N-scaling: 학습 건물 수에 따른 예측 성능 변화

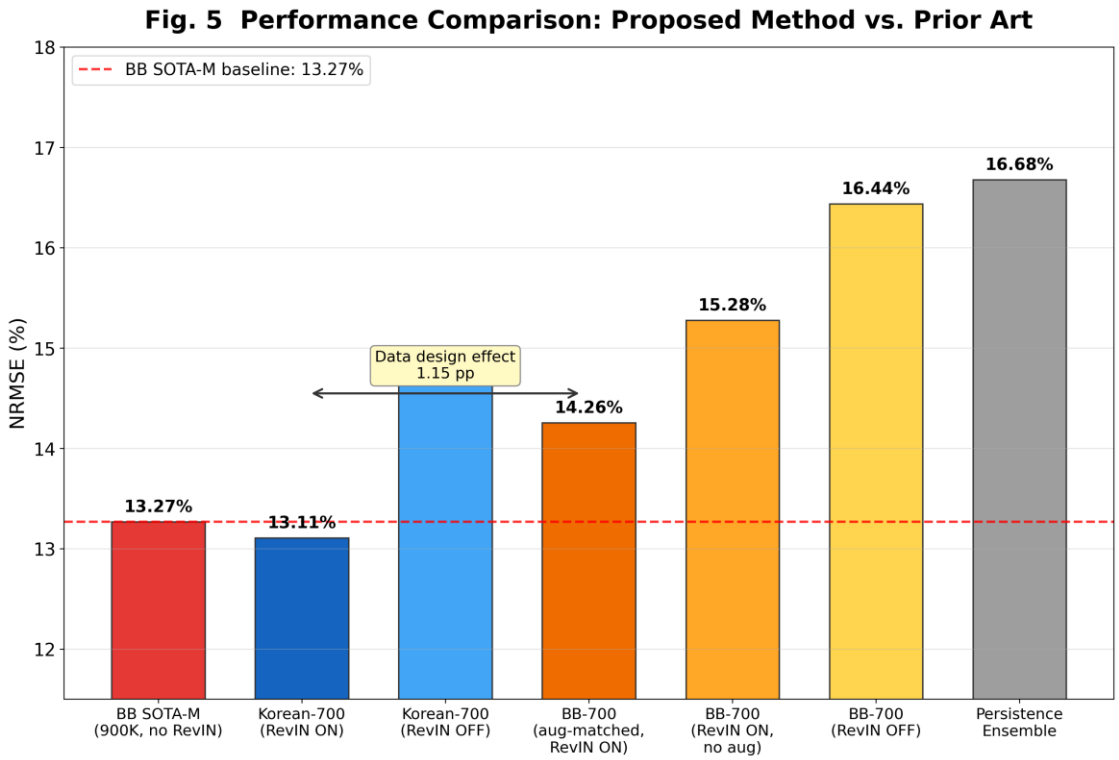

도 5 — 본 발명과 종래 기술 성능 비교